

# ATLAS (Automated Text & Language Assessment System)

Sistem Hibrida Komputasional Linguistik & Pendukung Keputusan untuk Assessment Linguistik & Sintaksis Ujaran Anak Autisme.

## Gambaran Umum

ATLAS adalah sistem berbasis **Streamlit** yang menganalisis ujaran anak autisme secara sintaksis dan pragmatik. Sistem menggabungkan **hybrid parser SPOK** (rule-based expanded lexicon untuk visualisasi + rule-based mini untuk ML), **model Machine Learning Random Forest**, serta **kalkulator klinis berbasis DSM-5** untuk menghasilkan diagnosis tingkat keparahan autisme dan rekomendasi intervensi terapi.

## Navigasi Aplikasi

Aplikasi memiliki 3 halaman yang dapat diakses melalui navigasi atas:

| Halaman        | Ikon                           | Fungsi                                                                               |
|----------------|--------------------------------|--------------------------------------------------------------------------------------|
| Analisis       | :material/<br>quick_reference: | Form input ujaran → parsing SPOK → prediksi ML → skor IKLA → rekomendasi terapi      |
| Dataset        | :material/table:               | Tabel interaktif dataset + visualisasi distribusi data (ASD, JK, kategori, MLU, dll) |
| Evaluasi Model | :material/analytics:           | Confusion matrix, cross-validation, classification report, feature importance        |

## Alur Proses (Pipeline)

Input Ujaran Anak



Tahap 1: Text Preprocessing

- Case folding
- Cleaning (hapus angka, tanda baca, emoji)
- Whitespace normalization



Tahap 2: Hybrid Parsing SPOK

2a. Rule-based Expanded  
Lexicon – untuk  
visualisasi anotasi  
~200+ kata (verba, nomina,  
keterangan, negasi, modal)



2b. Rule-based Mini –  
untuk feature ML  
Kamus mini + logika posisi  
Output: S+P+O / Ket+S+P+O



Tahap 3: Ekstraksi Fitur  
3a. Kompleksitas (K1-K4)  
3b. Intensi Komunikasi  
(Protesting, Requesting,  
Answering, Commenting)



Tahap 4: Prediksi ML  
- Random Forest (100 trees)  
- Fitur: TF-IDF + OneHot +  
StandardScaler  
- Akurasi: 93.96%  
Output: Belum Berkembang /  
Berkembang Sedang /  
Sudah Mahir



Tahap 5: Kalkulator IKLA  
- 6 komponen (Sintaksis,  
Leksikal, Pragmatik,  
Echolalia, Inisiasi,  
ASD Level)  
- Skor total maks: 90  
- Output: Level DSM-5  
(Ringan/Sedang/Berat)



Tahap 6: Sanity Check  
- Validasi MLU vs level  
- Validasi IKLA vs level  
- Koreksi inkonsistensi



Tahap 7: Rekomendasi  
- 12 skenario rekomendasi  
terapi  
- Rekomendasi tambahan per  
komponen skor rendah

## Detail Tahapan

### Tahap 1: Text Preprocessing (app\_pages/home.py : 12)

| Langkah      | Proses                                    |
|--------------|-------------------------------------------|
| Case folding | teks.lower()                              |
| Cleaning     | Hapus [^a-z\s] (angka, tanda baca, emoji) |
| Whitespace   | Normalisasi spasi berlebih                |

### Tahap 2: Hybrid Parsing SPOK

#### 2a. Rule-based Expanded Lexicon — untuk Visualisasi

Parser dengan leksikon diperluas (~80 verba, ~80 nomina, ~30 keterangan, 6 negasi, 6 modal) untuk anotasi SPOK berwarna via st-annotated-text.

| Kategori    | Jumlah | Contoh                                                                |
|-------------|--------|-----------------------------------------------------------------------|
| KATA_VERBA  | ~80    | makan, minum, baca, cuci, beli, lari, mandi, tidur, tulis, buka, ...  |
| KATA_NOMINA | ~80    | saya, mama, papa, kakak, adik, buku, sepeda, piring, baju, bola, ...  |
| KATA_KET    | ~30    | kemarin, tadi, nanti, di, ke, dari, sangat, cepat, sudah, sedang, ... |
| KATA_NEGASI | 6      | tidak, bukan, jangan, belum, tak, tiada                               |
| KATA_MODAL  | 6      | mau, ingin, bisa, dapat, harus, akan                                  |

#### Aturan Parsing:

- Echolalia/Repetisi:** Input echolalia == "Ya" → label "Echolalia"; token >= 2 dan semua sama → "Repetisi"
- Frasa Keterangan Bersambung:** Preposisi di/ke/dari → kata berikutnya otomatis Ket
- Negasi:** tidak, bukan, dll → Negasi
- Modal** → **P:** mau, ingin, bisa, dapat, harus, akan → P + tandai has\_predikat

= True

5. **Verba** → **P**: Semua verba selalu jadi P, tidak peduli status has\_predikat (verba setelah modal tetap P, bukan O)
6. **Nomina**: Sebelum predikat pertama → S; setelah predikat → O
7. **Fallback**: Kata di luar kamus → S (jika belum ada S), P (jika S sudah ada dan belum ada predikat), O (jika sudah ada predikat)
8. **Reduksi Duplikasi**: Label identik berurutan digabung (P+P → P)

## 2b. Rule-based Parser — untuk Feature ML

Parser berbasis kamus leksikon mini dan logika posisi kata (kiri ke kanan). Output tetap dipertahankan dalam format S+P+O yang konsisten dengan data training, sehingga **model ML tidak perlu retrain**.

**Kamus Leksikon:**

| Kategori         | Kata Kunci                                                                                                       |
|------------------|------------------------------------------------------------------------------------------------------------------|
| Negasi           | tidak, bukan, jangan, belum                                                                                      |
| Keterangan (Ket) | kemarin, besok, tadi, sekarang, sore, pagi, sangat, cepat, di, ke, dari, sini, sana, epat                        |
| Modal (P)        | mau, ingin (kata kerja bantu, selalu jadi P)                                                                     |
| Predikat (P/O)   | minta, makan, minum, lari, main, duduk, lihat, putar, tidur, mandi, siram, baca, pergi                           |
| Nomina (S/O)     | aku, saya, kamu, dia, mama, papa, anak, mobil, bunga, sepeda, kucing, susu, air, buku, kebun, binatang, ini, itu |

**Aturan Parsing:**

1. **Echolalia**: Jika input echolalia == "Ya" → label "Echolalia"
2. **Repetisi**: Jika token >= 2 dan set(token) hanya 1 unsur → label "Repetisi"
3. **Frasa Keterangan Bersambung**: Preposisi di/ke/dari → kata berikutnya otomatis Ket
4. **Negasi**: tidak, bukan, jangan, belum → Negasi
5. **Modal** → **P**: mau, ingin → P + tandai has\_predikat = True
6. **Verba**: Sebelum predikat → P; setelah predikat → O
7. **Logika S vs O**: Nomina sebelum predikat pertama = S; nomina setelah predikat = O
8. **Fallback**: Kata di luar kamus → S (jika belum ada S), P (jika S sudah ada dan belum ada predikat), O (jika sudah ada predikat)

9. **Reduksi Duplikasi:** Deretan label identik berurutan digabung (contoh: [Ket, Ket, Ket] → [Ket])

10. **Output:** String dipisah +, contoh: "S+P+O", "Echolalia", "Repetisi"

### Tahap 3a: Kompleksitas Kalimat (app\_pages/home.py : 155)

| Aturan                                                                      | Hasil                         |
|-----------------------------------------------------------------------------|-------------------------------|
| Tidak ada + ATAU struktur = echolalia/repetisi/negasi/tidak teridentifikasi | <b>Kata Tunggal (K1)</b>      |
| + muncul 1 kali                                                             | <b>Frasa (K2)</b>             |
| + muncul >= 3 kali                                                          | <b>Kalimat Majemuk (K4)</b>   |
| Selainnya (2 tanda +)                                                       | <b>Kalimat Sederhana (K3)</b> |

### Tahap 3b: Intensi Komunikasi (app\_pages/home.py : 166)

| Aturan Kata Kunci                                       | Intensi           |
|---------------------------------------------------------|-------------------|
| Mengandung tidak, bukan, jangan, takut, maaf            | <b>Protesting</b> |
| Mengandung mau, ingin, minta, ambil, buka, lagi, tolong | <b>Requesting</b> |
| Konteks = instruksi ATAU mengandung sudah, iya, belum   | <b>Answering</b>  |
| Default                                                 | <b>Commenting</b> |

### Tahap 4: Prediksi Machine Learning (model.ipynb, implementasi di app\_pages/home.py : 12–155)

**Model:** Random Forest Classifier (100 trees, random\_state=42, class\_weight='balanced')

#### Pipeline Preprocessing:

| Tipe Data   | Kolom                                                                        | Transformasi                         |
|-------------|------------------------------------------------------------------------------|--------------------------------------|
| Teks        | Ujaran Bersih                                                                | TF-IDF Vectorizer (max 100 features) |
| Kategorikal | ASD, Echolalia, Struktur Sintaksis, Kompleksitas Kalimat, Intensi Komunikasi | OneHotEncoder                        |
| Numerik     | MLU                                                                          | StandardScaler                       |

**Target** (3 kelas): Belum Berkembang (33), Berkembang Sedang (48), Sudah Mahir (51)

**Kinerja Model** (5-fold Stratified Cross-Validation):

- Akurasi: **93.96%**
- F1-score (macro): **93.99%**

**Fallback** (jika file .pkl tidak ditemukan):

- $MLU \leq 1 \rightarrow$  Belum Berkembang
- $MLU > 1 \rightarrow$  Sudah Mahir

## Tahap 5: Kalkulator IKLA — DSM-5 (app\_pages/home.py:178)

Skor total maksimal: **90**, terdiri dari 6 komponen:

| Komponen  | Maks | Kriteria Skor                                                    |
|-----------|------|------------------------------------------------------------------|
| Sintaksis | 24   | K4 / (K3 & $MLU \geq 3$ ) = 24; K2 / $MLU = 2$ = 16; lainnya = 8 |
| Leksikal  | 16   | Token $> 3$ = 16; Token $\geq 2$ = 10; Token = 1 = 5             |
| Pragmatik | 20   | Commenting/Answering = 20; Requesting = 13; Protesting = 9       |
| Echolalia | 12   | "Tidak" = 12; "Ya" = 3                                           |
| Inisiasi  | 8    | Bermain/Bercerita = 8; Percakapan = 5; Deskripsi/Instruksi = 3   |
| ASD Level | 10   | ASD-1 = 10; ASD-2 = 6; ASD-3 = 2                                 |

**Opsi "Tidak tahu / Otomatis":** Jika pengguna tidak mengetahui tingkat ASD anak, sistem menggunakan **ASD-2** sebagai default netral.

### Output Diagnosis DSM-5

| Total Skor | Diagnosis                       |
|------------|---------------------------------|
| $\leq 30$  | <b>Autisme Berat (Level 3)</b>  |
| 31 – 60    | <b>Autisme Sedang (Level 2)</b> |
| $> 60$     | <b>Autisme Ringan (Level 1)</b> |

## Tahap 6: Sanity Check (app\_pages/home.py : 371)

### Validasi MLU vs Level Pemahaman

| Level             | Rentang MLU |
|-------------------|-------------|
| Belum Berkembang  | 0 – 1       |
| Berkembang Sedang | 2 – 3       |
| Sudah Mahir       | >= 4        |

Jika prediksi ML tidak sesuai rentang MLU → koreksi paksa ke level yang sesuai.

### Validasi IKLA vs Level

- "Sudah Mahir" tapi IKLA <= 60 → turunkan ke "Berkembang Sedang"
- "Berkembang Sedang" tapi IKLA <= 30 → turunkan ke "Belum Berkembang"

## Tahap 7: Rekomendasi Terapis (app\_pages/home.py : 203)

### Matriks Rekomendasi (3 level × 4 intensi = 12 skenario)

| Level                    | Protesting                        | Requesting               | Commenting                | Answering                          |
|--------------------------|-----------------------------------|--------------------------|---------------------------|------------------------------------|
| <b>Belum Berkembang</b>  | PECS kartu "tidak"                | Teknik Manding vokal     | Joint attention & imitasi | Imitasi vokal Ya/Tidak             |
| <b>Berkembang Sedang</b> | Frasa "tidak mau" + jadwal visual | Ekspansi 1 → 2 kata      | Teknik Cloze kalimat      | Visual support + prompt bertingkat |
| <b>Sudah Mahir</b>       | Alasan penolakan dg "karena"      | Kalimat lengkap + santun | Story Retelling 3 klausa  | Stimulasi "Mengapa"/"Bagaimana"    |

Setiap rekomendasi mencakup: **Target, Metode, Contoh, Frekuensi, Indikator.**

### Rekomendasi Tambahan

Jika skor komponen < 50% dari maksimal, sistem menampilkan catatan per komponen:

- **Sintaksis:** Latih perluasan 1 → 2 → 3 kata
- **Leksikal:** Ekspos 3-5 kosakata baru per sesi
- **Pragmatik:** Fokus turn-taking & kontak mata
- **Echolalia:** Intervensi potong-rantai
- **Inisiasi:** Ciptakan situasi butuh inisiatif
- **ASD Level:** Sesuaikan target intervensi dengan tingkat keparahan — fokus pada komunikasi dasar (PECS/isyarat) untuk ASD-3

Jika MLU <= 2 → rekomendasi ekspansi kalimat (+1 kata dari produksi anak).

---

## Dataset

Dataset dapat dieksplorasi secara interaktif melalui halaman **Dataset** pada aplikasi, yang menampilkan tabel lengkap dengan filtering serta visualisasi distribusi berdasarkan berbagai kategori (ASD, jenis kelamin, konteks, kompleksitas, intensi, MLU, dll).

**Sumber:** 65 anak autisme (A001–A065), 2 ujaran per anak = **132 sampel**

Dataset final (`dataset.csv`) memiliki **14 kolom** sebagai berikut:

| #  | Kolom                | Deskripsi                                                                      | Asal                                                |
|----|----------------------|--------------------------------------------------------------------------------|-----------------------------------------------------|
| 1  | ID Anak              | Kode unik (A001–A065)                                                          | Data mentah                                         |
| 2  | JK                   | Jenis kelamin (L/P)                                                            | Data mentah                                         |
| 3  | ASD                  | Tingkat autisme (ASD-1/2/3)                                                    | Data mentah                                         |
| 4  | Usia                 | Usia dalam format tahun;bulan                                                  | Data mentah                                         |
| 5  | Konteks              | Bermain, Percakapan, Bercerita, Deskripsi Gambar, Instruksi                    | Data mentah                                         |
| 6  | Ujaran Anak          | Teks asli ujaran anak                                                          | Data mentah                                         |
| 7  | Struktur Sintaksis   | Pola SPOK label manual                                                         | Data mentah                                         |
| 8  | MLU                  | Mean Length of Utterance (jumlah kata)                                         | Data mentah                                         |
| 9  | Echolalia            | Ya/Tidak                                                                       | Data mentah                                         |
| 10 | Ujaran Bersih        | Hasil preprocessing (case folding + cleaning)                                  | preprocessing ( <code>app_pages/home.py:12</code> ) |
| 11 | Token                | Hasil tokenisasi dalam bentuk list                                             | preprocessing ( <code>app_pages/home.py:12</code> ) |
| 12 | Kategori Pemahaman   | Belum Berkembang / Berkembang Sedang / Sudah Mahir                             | labeling manual saat pembuatan dataset              |
| 13 | Kompleksitas Kalimat | K1 (Kata Tunggal) / K2 (Frasa) / K3 (Kalimat Sederhana) / K4 (Kalimat Majemuk) | <code>app_pages/home.py:155</code>                  |
| 14 | Intensi Komunikasi   | Protesting / Requesting / Answering / Commenting                               | <code>app_pages/home.py:166</code>                  |



# Evaluasi Model

Halaman **Evaluasi Model** menyediakan analisis performa model Random Forest secara mendetail:

| Fitur                 | Deskripsi                                                                                |
|-----------------------|------------------------------------------------------------------------------------------|
| Confusion Matrix      | Heatmap prediksi model vs label aktual pada seluruh dataset                              |
| Cross-Validation      | 5-fold Stratified CV — akurasi per fold, rata-rata akurasi (93.96%), F1-score (93.99%)   |
| Classification Report | Precision, recall, F1-score per kelas (Belum Berkembang, Berkembang Sedang, Sudah Mahir) |
| Feature Importance    | Top 20 fitur paling penting hasil ekstraksi dari Random Forest                           |

Model dievaluasi menggunakan metrik yang sama seperti pada notebook `model.ipynb`.

## Struktur File

|                               |                                                      |
|-------------------------------|------------------------------------------------------|
| └─ app.py                     | # Entry point – navigasi multipage                   |
| (st.navigation)               |                                                      |
| └─ app_pages/                 | # Halaman-halaman aplikasi                           |
| └─ home.py                    | # Halaman Analisis (form input + dashboard)          |
| └─ dataset.py                 | # Halaman Dataset (tabel + visualisasi data)         |
| └─ evaluation.py              | # Halaman Evaluasi Model (confusion matrix + metrik) |
| └─ model_autism_syntax_rf.pkl | # Model ML terlatih (Random Forest)                  |
| └─ model.ipynb                | # Notebook training model                            |
| └─ version.py                 | # Cek versi pustaka                                  |
| └─ requirements.txt           | # Dependensi Python                                  |
| └─ README.md                  | # Dokumentasi sistem                                 |
| └─ .streamlit/                |                                                      |
| └─ config.toml                | # Tema Fluent (Light, Blue #0078D4)                  |
| └─ dataset/                   |                                                      |
| └─ dataset.csv                | # Dataset final (14 kolom, 132 sampel)               |

## Teknologi

| Komponen            | Tools                                   |
|---------------------|-----------------------------------------|
| Framework           | Streamlit 1.58.0                        |
| Syntactic Parsing   | Rule-based Expanded Lexicon (~200 kata) |
| Machine Learning    | scikit-learn 1.6.1 (Random Forest)      |
| Data Processing     | pandas 2.2.3                            |
| Model Serialization | joblib >= 1.3                           |
| Text Processing     | regex (re)                              |

| Komponen      | Tools                                          |
|---------------|------------------------------------------------|
| Anotasi Warna | st-annotated-text                              |
| Visualisasi   | matplotlib, Streamlit native charts            |
| Ikon          | Google Material Symbols                        |
| Tema          | Fluent Design (Light, Blue #0078D4, Open Sans) |
| Lingkungan    | Python 3.12                                    |
| Deployment    | Streamlit Cloud                                |

---

## Tampilan & Tema

Aplikasi menggunakan tema **Fluent Design** (terinspirasi Windows 11) dengan:

- **Warna primer:** Biru #0078D4
- **Font:** Open Sans (body) + Fira Code (code)
- **Base font size:** 16px untuk keterbacaan optimal
- **Ikon:** Material Symbols untuk tombol, label, dan status

File konfigurasi tema: `.streamlit/config.toml`

---

## Cara Menjalankan

```
# Install dependencies
pip install -r requirements.txt

# Jalankan aplikasi
streamlit run app.py
```

---

## Catatan Klinis

Sistem ini dirancang sebagai **alat bantu keputusan** (decision support system) untuk terapis dan klinisi. Hasil analisis dan rekomendasi bersifat indikatif dan tidak menggantikan diagnosis profesional dari dokter/psikolog klinis.

---